

Nome: Hyghor Miranda Côrtes

Compilado do artigo **A eficácia irracional dos dados**, dos autores **Alon Halevy, Peter Norvig, e Fernando Pereira**

As fórmulas matemáticas $f = ma$ e $e = mc^2$ explicam grande parte da física, em contraste com as ciências humanas, que se mostram bem mais resistentes à elegante matemática. Quando tratamos de processamento de linguagem natural e campos correlatos ficamos geralmente fadados a teorias complexas, porém necessitamos, talvez, parar de agir nos agarrando a teorias complexas, ao tratar o processamento de linguagem natural, e fazer uso melhor de um aliado que seria a *eficácia irracional dos dados*.

O Browns Corpus (da Universidade de Browns), era um corpus que analisava palavras em inglês no uso da linguagem natural, e este foi comparado àquele lançado pela Google, no ano de 2006. As vantagens do Brown Corpus eram: usar tags e ser cuidadosamente corrigido à mão, frente às desvantagens do corpus da Google, que eram: o uso de frases incompletas, erros de ortografia e de gramática etc. No entanto, apesar disso, o resultado do corpus Google era melhor, por ser um milhão de vezes maior que o de Brown, em análise de palavras, e este, apesar das limitações, superava o de Brown pela sua maior capacidade.

Os maiores sucessos no aprendizado de máquina relacionado ao idioma natural foram o reconhecimento estatístico da fala e a tradução automática estatística. O motivo é que a tradução é uma tarefa natural rotineiramente realizada todos os dias para uma necessidade humana real (pense nas operações da União Europeia ou de agências de notícias). O mesmo se aplica à transcrição de fala (pense em transmissões de legenda). Ou seja, um grande conjunto de treinamento do comportamento de entrada e saída que procuramos automatizar está disponível para nós na natureza.

Nesse contexto, nos voltamos para o aprendizado em escala na Web. Uma primeira lição é, usar dados disponíveis em grande escala, em vez de esperar dados anotados que não estão disponíveis. Outra lição importante é, que, tratando-se de métodos estatísticos em reconhecimento de fala e tradução automática, a memorização é uma boa política se você tiver muitos dados de treinamento. Os modelos de linguagem estatística usados nas duas tarefas consistem principalmente de *n-gramas*, que são enormes bancos de dados de probabilidades de sequências curtas de palavras consecutivas. Os pesquisadores fizeram muito trabalho na estimativa das probabilidades de novos *n-gramas* mas, invariavelmente, modelos simples e muitos dados superaram modelos mais elaborados com base em menos dados.

Infelizmente, o sucesso dos modelos *n-gram* levou a uma falsa dicotomia. Muitas pessoas agora acreditam que existem apenas duas abordagens para o processamento de linguagem natural: uma *abordagem profunda*, que se baseia em gramática e ontologias codificadas manualmente, e uma *abordagem estatística*, que se baseia em aprendizagem de estatísticas de grandes corpus. Na realidade, surgem três problemas ortogonais: escolher a linguagem de representação, codificar um modelo nesse idioma e realizar inferência no modelo. Cada problema desse pode ser tratado de várias maneiras, resultando em dezenas de abordagens.

A *Web Semântica* é uma convenção para linguagens de representação formal que permite que os serviços de *software* interajam entre si “sem a necessidade de inteligência artificial”, podendo assim interoperar com outros serviços que usam o mesmo padrão ou um diferente, com uma tradução conhecida no padrão escolhido. O problema de entender a fala e a escrita humana - o *problema de interpretação semântica* -, é bem diferente do problema da interoperabilidade de serviços de *software*. A interpretação semântica lida com linguagens naturais imprecisas e ambíguas, enquanto a interoperabilidade de serviço torna os dados precisos para que os programas que operam os dados funcionem de forma efetiva.

A criação de serviços da *Web Semântica* é um desafio sociológico e de engenharia. Portanto, mesmo que entendamos a tecnologia necessária, devemos lidar com obstáculos significativos: escrita de ontologia (há uma longa lista de conceitos raramente usados que são muito caros para formalizar com a tecnologia atual), dificuldade de implementação (criar um serviço da Web e torná-lo compatível com os protocolos da Web Semântica é ainda difícil) concorrência (em alguns domínios, cada uma das facções concorrentes deseja promover sua própria ontologia) e imprecisão e decepção (não temos metodologia estabelecida para lidar com premissas equivocadas ou com atores que mentem, trapaceiam ou enganam).

Já os desafios para alcançar uma *interpretação semântica* precisa são diferentes. Tratam da interpretação do conteúdo, ou seja, aprender o máximo possível sobre o contexto do conteúdo para desambiguá-lo corretamente. Essa questão, de interpretação semântica, permanece, independentemente de estarmos usando ou não uma estrutura da *Web Semântica*. O mesmo significado pode ser expresso de muitas e diferentes maneiras, e a mesma expressão pode expressar muitos e diferentes significados. O que precisamos, são métodos para inferir relacionamentos entre cabeçalhos de coluna ou menções de entidades no mundo. Essas inferências podem estar incorretas às vezes, mas, se forem bem-sucedidas, podemos conectar coleções de dados díspares e, assim, melhorar substancialmente nossa interação com os dados da Web. Curiosamente, também aqui os dados em escala da Web podem ser uma parte importante da solução.

Concluindo, processamento de linguagem natural é complexo e, em contrapartida, há exemplos de pesquisas que comprovam o tratamento irracional de dados de forma eficiente, além da comparação do Brown Corpus com corpus da Google, nos indicando então seguir os dados. Sempre que possível, é interessante escolher uma representação que possa usar um aprendizado não supervisionado em dados não rotulados - o que é muito mais abundante do que dados rotulados -, e representar todos os dados com um modelo não paramétrico, em vez de tentar resumi-lo com um modelo paramétrico, pois, com fontes de dados muito grandes, os dados contêm muitos detalhes. Para aplicativos de linguagem natural, confie que a linguagem humana já desenvolveu palavras para os conceitos importantes.